BS6204 Deep Learning for Biomedical Science · 小组项目

Twelve to One

Lead-Robust Deep Learning for Multi-label ECG Diagnosis and Wearable Triage on PTB-XL

项目简介：我们做了什么、怎么做的、得到了什么

一句话版本

心电图（ECG）在医院里用 12 个导联记录，智能手表只能记录 1 个导联（Lead I）。我们在公开数据集 PTB-XL 上，用三种深度学习模型、四种训练策略，把导联从 12 个一步步减到 1 个，按**事先定好的规则**逐个诊断判断“少导联还能不能代替 12 导联做初筛”。答案是：**30 个“诊断 × 导联配置”组合里只有 1 个过关**（胸导联 6 个导联筛 ST/T 改变），单导联可以帮忙做“正常/异常”分诊，但不能代替 12 导联做这 5 类诊断。

课程	BS6204（Dr Liu Yong），NTU
提交截止	2026-10-28 23:59（报告 + PPT + 代码）
本文用途	让组员 / 同学 15 分钟内看懂整个项目；正式内容以英文报告为准
版本日期	2026-10-08

目录

1 先读这一页：项目速览 3

2 背景：为什么要做这个 4

2.1 心电图和“导联” 4
2.2 我们关心的问题 4
2.3 三个研究问题 4

3 数据与任务 4

3.1 PTB-XL 数据集 4
3.2 五个诊断大类（T1 的输出） 5
3.3 两个任务 5
3.4 六种导联配置 5
3.5 外部验证数据：Chapman-Shaoxing/Ningbo 5

4 方法：我们比较了什么 6

4.1 基线（B0–B2） 6
4.2 三种深度模型（三种“归纳偏置”） 6
4.3 四种训练策略 7
4.4 统一的训练配方（保证公平） 7

5 怎么评价：事先定好的“初筛规则” 7

5.1 指标 7
5.2 初筛规则（核心!） 8
5.3 统计方法 8
5.4 防泄漏与可复现 8

6 实验清单 9

7 主要结果 9

7.1 RQ1：12 导联下三种架构差不多，都远好于传统方法 9
7.2 RQ2：导联越少越差，Lead I 掉得最多 10
7.3 结论矩阵：30 个格子只有 1 个过关 11
7.4 RQ2：训练策略补不回来丢掉的信息 12
7.5 RQ3：自监督预训练帮了 Transformer（E8） 13
7.6 RQ3：噪声、分诊和外部医院 13

8 结论：带走这四句话 **14**

9 常见问题（答辩准备） **15**

10 术语小词典 **16**

11 压缩包里有什么、怎么用 **16**

11.1 目录导览 16

11.2 没放进去的东西 17

11.3 推荐阅读顺序 17

1 先读这一页：项目速览

要解决的问题	智能手表那样的单导联心电，能在多大程度上代替医院的 12 导联心电做心脏病初筛?
数据	PTB-XL v1.0.3，21,388 条 10 秒 12 导联心电（100 Hz），官方按病人分好的训练 / 验证 / 测试折；外加 Chapman 医院数据 34,815 条做外部验证
任务	T1：5 个诊断大类多标签分类（NORM / MI / STTC / CD / HYP）；T2：正常 vs 异常二分类分诊
输入	6 种导联配置：12 导联 → 肢体 6 导联 → 胸前 6 导联 → I+II → 只有 II → 只有 I
模型	ResNet1d（卷积）、CNN-BiLSTM（循环）、ECG-ViT（注意力），全部自己用 PyTorch 写
策略	S1 从头训练；S2 迁移学习；S3 导联自适应 LA-ResNet（我们自己的设计）；S4 自监督预训练
判断标准	看结果之前就定好：ΔAUROC 的 95% 置信区间下界 ≥ -0.02 且特异度 90% 时灵敏度 ≥ 0.80 才算“可以初筛”
规模	主网格 102 次训练 + 自监督 14 次 + 基线，3 个随机种子，1,000 次 bootstrap 求置信区间
主要结论	30 个格子 29 个不能替代；只有“胸 6 导联 + STTC”过关；Lead I 上 MI 最差（灵敏度只有 0.45）

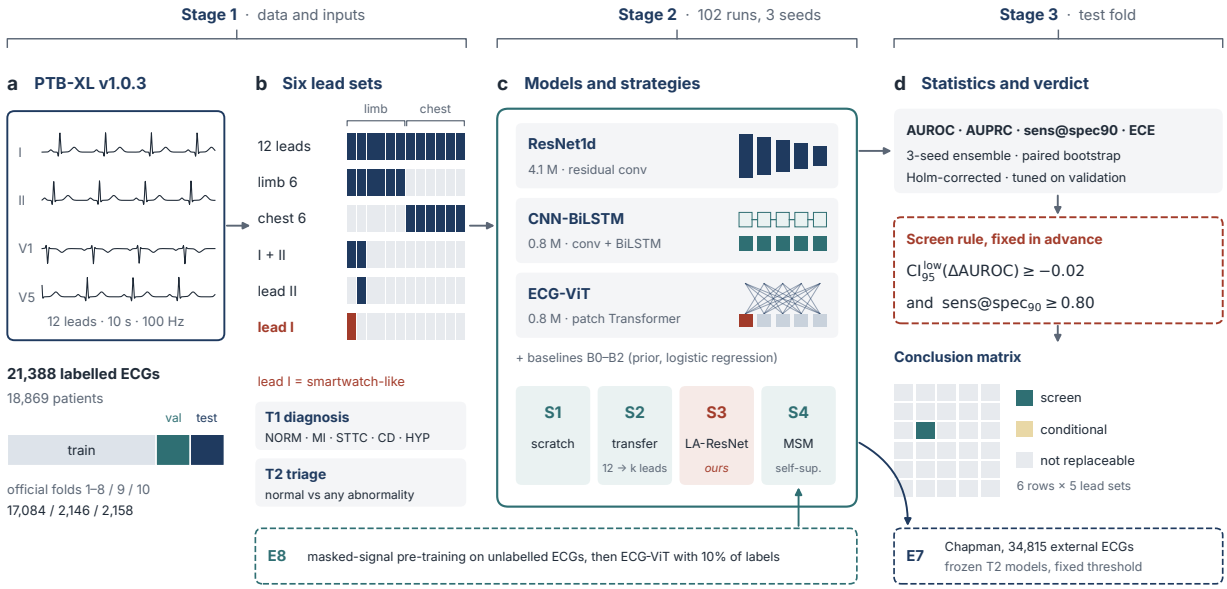


图 1: 研究设计总图（报告 Figure 1）。a：PTB-XL 数据和官方分折；b：六种导联配置（红色是手表那样的 Lead I）；c：三种模型 + 四种训练策略 + 三个基线；d：评价指标、事先定好的“初筛规则”和最后的结论矩阵。虚线框是两个扩展实验：E8 自监督预训练、E7 外部医院验证。

2 背景：为什么要做这个

2.1 心电图和“导联”

心电图记录的是心脏每次跳动时的电活动。医院标准做法是在四肢和胸前贴 10 个电极，组合出 **12 个导联**，每个导联相当于从一个不同角度“看”心脏：

- **肢体导联（6 个）**：I、II、III、aVR、aVL、aVF，主要看心脏在“额面”（上下左右）的电活动；
- **胸前导联（6 个）**：V1–V6，贴在胸口，主要看“水平面”（前后），对心脏前壁、侧壁的变化很敏感。

智能手表（比如 Apple Watch 的 ECG 功能）是一只手腕 + 另一只手指接触表冠，只能记录相当于 **Lead I** 的一个导联。手表方便、随时可测，但信息少了 11 个角度。

2.2 我们关心的问题

已经有很多研究证明深度学习在 12 导联上效果很好，也有研究报告单导联在某一种病上效果不错。但临床上真正要问的是：**对每一种诊断**，减少导联后掉了多少？掉的这部分是否还在可以接受的范围内？大多数论文只报告“平均 AUROC 掉了 0.0x”，这不能回答“能不能用”。所以我们的核心做法是：**在看任何结果之前，先写下一条明确的“能不能替代”的规则**，然后对每个“诊断 × 导联配置”格子逐个判定。

2.3 三个研究问题

RQ1 在 12 导联上，卷积（CNN）、循环（RNN/LSTM）、注意力（Transformer）三类结构，判别能力和概率校准有什么差别？

RQ2 导联减少后，5 类诊断各自掉多少？迁移学习、导联自适应这些训练策略能不能把掉的补回来？

RQ3 贴近真实穿戴场景（单导联 + 噪声 + 标签少 + 换一家医院）时，哪种方法更可靠？单导联能不能做“正常 / 异常”分诊？

3 数据与任务

3.1 PTB-XL 数据集

- 公开数据集（Wagner et al., *Scientific Data* 2020），21,799 条 10 秒 12 导联静息心电，来自 18,869 位病人，由心脏科医生标注。
- 每条记录的诊断语句被映射成 5 个大类（按 Strodthoff et al. 2021 基准的做法），至少有一个大类的 **21,388 条**被保留。
- 用 **100 Hz** 版本：每个导联 10 秒 = 1,000 个采样点。这是 PTB-XL 基准的标准设置，也让 100 多次训练能在一台笔记本 GPU 上跑完。

- **分折完全用官方的**：第 1–8 折训练（17,084 条），第 9 折验证（2,146 条），第 10 折测试（2,158 条）。同一病人的所有记录只在同一折里，所以**不会有病人层面的数据泄漏**。
- 标准化（每个导联减均值除标准差）的参数只用训练集估计，再原样用到验证、测试和外部数据上。

3.2 五个诊断大类（T1 的输出）

缩写	英文	中文 / 通俗解释	测试集占比
NORM	Normal ECG	正常心电图	44.6%
MI	Myocardial infarction	心肌梗死（心梗），心肌缺血坏死留下的电活动改变	25.5%
STTC	ST/T change	ST 段 / T 波改变，常见于心肌缺血、电解质紊乱等	24.1%
CD	Conduction disturbance	传导阻滞，例如束支传导阻滞，电信号“走路”出了问题	23.0%
HYP	Hypertrophy	心室肥厚，心肌变厚导致电压升高	12.1%

一条记录可以同时有多个标签（比如同时有 MI 和 CD），所以加起来超过 100%。

3.3 两个任务

- **T1 多标签诊断**：模型输出 5 个独立的概率（5 个 sigmoid），每个大类判一次“有 / 没有”。
- **T2 正常 / 异常分诊**：只输出 1 个概率。只要有 MI、STTC、CD、HYP 任意一个就算“异常”。这正是手表最可能被问的问题：“这个人需不需要去医院做 12 导联？”注意 T2 不等于“非 NORM”：测试集有 51 条同时标了 NORM 和某个异常大类，在 T2 里算异常。

3.4 六种导联配置

配置名	包含的导联	代表什么设备 / 为什么选
12lead	全部 12 个	医院标准，作为参照
limb6	I, II, III, aVR, aVL, aVF	只有肢体导联的设备、6 导联贴片
chest6	V1–V6	只有胸前信息、没有肢体导联
2lead	I + II	两电极类设备
leadII	II	传统的“节律条”
leadI	**I**	**智能手表那样的单导联**

每个配置都是**单独训练、单独测试**：比如 Lead I 模型训练时就只看 Lead I 的信号（S3 LA-ResNet 例外，见下文）。

3.5 外部验证数据：Chapman-Shaoxing/Ningbo

为了看模型换一家医院还灵不灵（E7），我们用了 PhysioNet 上的 Chapman-Shaoxing/Ningbo 数据库（中国两家医院，45,152 条 500 Hz 12 导联心电）。它的诊断是 SNOMED-CT 编码，我们按

PhysioNet/CinC 2021 挑战赛官方的等价表映射到 PTB-XL 的大类（称为 **v2 映射**）：只有全部编码都是窦性心律类才算“正常”，至少一个编码映射到 MI/STTC/CD/HYP 才算“异常”，其余（比如只有房颤）排除。最后纳入 **34,815 条**（异常 16,092，正常 18,723）。信号转成毫伏、降采样到 100 Hz、裁成 10 秒。模型**完全不重新训练**，直接拿 PTB-XL 上训练好的去测。

4 方法：我们比较了什么

4.1 基线（B0–B2）

基线的作用是证明深度学习确实“学到了东西”，而不是数据本身太简单。

- **B0 先验**：对每条记录都输出训练集里各类的比例，AUROC 必然 = 0.5，相当于“瞎猜”。
- **B1 逻辑回归（原始波形）**：把信号 4 倍平均池化后直接丢给逻辑回归。结果 AUROC 只有 0.51，几乎是瞎猜——原因是不同记录里心跳出现的时间点不同，“第 300 个采样点”在每条记录里含义都不一样。
- **B2 逻辑回归（平移不变特征）**：B1 失败后补加的。每个导联算 22 个不受时间平移影响的特征（13 个幅值统计、2 个斜率统计、5 个频带的相对功率、自相关周期和强度作为心率估计），再用同样的逻辑回归。12 导联 AUROC 0.863，和文献中的特征类方法（Wavelet+NN 0.874）接近，是一个合理的传统方法参照。B1 结果原样保留、照实报告。

4.2 三种深度模型（三种“归纳偏置”）

“归纳偏置”可以理解为模型结构里自带的“先入为主的假设”。我们选了三种假设完全不同的结构：

模型	参数量	结构要点	它“相信”什么
ResNet1d	4.07 M	一维残差网络：步长 2 的卷积（核 15）+ 最大池化，8 个残差块（核 7），通道 64→256，全局平均 + 最大池化拼接，dropout 0.2。感受野 1,291 个采样点（比 1,000 点的输入还长）	心电的关键是**局部波形形态**，一层层叠起来看
CNN-BiLSTM	0.79 M	卷积前端把长度缩成 1/4（250 步），两层双向 LSTM（隐层 128），再用加性注意力在时间上加权汇总	先看局部，再按**时间顺序**理解前后心跳的关系
ECG-ViT	0.82 M	一维 Vision Transformer：把 10 秒切成 50 个 200 ms 的小块（patch），线性嵌入到 128 维，加 CLS 标记和正弦位置编码，4 层 Transformer（4 个头），**多头自注意力是手写的**	几乎不假设局部性，任何两个时间段从第一层起就可以直接“对话”

4.3 四种训练策略

S1 从头训练

每种导联配置单独训练一个新模型。最朴素，也是最重要的对照。

S2 迁移学习

先用 12 导联训练好的 ResNet1d，把第一层换成对应导联数的输入层，并把保留下来那些导联原来的卷积核复制过去。两种做法：微调（全部层都训练，新层用正常学习率，主干用 0.1 倍学习率）和冻结（只训练新输入层和分类头，只做了 Lead I）。

S3 LA-ResNet（我们自己的设计）

一个模型服务所有导联配置。输入 24 个通道：12 个导联信号（缺失的导联填 0）+ 12 个 0/1“掩码”通道，告诉网络哪些导联是真实的。训练时每条记录 50% 概率用全部 12 导联，30% 概率随机选 5 种减少配置之一，20% 概率用随机导联子集。早停看 6 种配置验证 AUROC 的平均值。好处：部署时只需要一**个**模型文件。

S4 自监督预训练（E8）

先**不用标签**训练 ECG-ViT：随机遮住 50 个小块里的 8 个（约 15%），让模型把被遮住的波形“补”出来（类似 BERT 的完形填空 / MAE）。然后只用 **10% 的标签**微调分类，看能不能缓解“标签少”的问题。

4.4 统一的训练配方（保证公平）

所有模型共用同一个训练循环，差别只来自结构或策略本身：

- 损失：二元交叉熵（BCE with logits）；优化器 AdamW（学习率 10^{-3}，权重衰减 10^{-2}）；OneCycle 学习率调度（前 10% 预热）；batch 128；梯度裁剪 1.0；GPU 上混合精度。
- 最多 50 个 epoch，按验证集 macro AUROC 早停（patience 10），保留最好的权重。
- 数据增强：每导联幅度缩放、基线偏移、高斯噪声、最多 ±0.5 秒的循环平移。
- **没有针对任何单个模型调超参数**；主网格每个配置跑 3 个种子（0、1、2）。

5 怎么评价：事先定好的“初筛规则”

5.1 指标

- **AUROC**（ROC 曲线下面积）：主指标。0.5 = 瞎猜，1.0 = 完美；它不依赖阈值，适合比较不同发病率的类别。macro AUROC = 5 个类别 AUROC 的平均。
- **特异度 90% 时的灵敏度**（sens@spec90）：把阈值调到“10 个健康人里只误报 1 个”，这时能抓出多少病人。这是临床上更直观的数字。
- 另外还报告 AUPRC、F1/PPV/NPV（阈值在验证集上选）、Brier 分数、ECE 校准误差（以及温度缩放之后的 ECE）。

5.2 初筛规则（核心!）

在看任何减导联结果之前就定好的判定规则

对每一个“诊断 × 减少后的导联配置”格子，和同一架构族的 12 导联模型比：

1. **判别力不明显变差**：ΔAUROC（减导联 − 12 导联）的配对 bootstrap 95% 置信区间**下界** ≥ -0.02；
2. **工作点有用**：特异度 90% 时灵敏度 ≥ 0.80。

两条都满足 = **可初筛（screen）**；只满足一条 = **有条件（conditional）**；都不满足 = **不能替代（not replaceable）**。

敏感性分析：把 0.02 换成 0.01 或 0.03 再判一次。

“主方案”怎么选：在覆盖全部 5 种减少配置的方案里，选**验证集**平均 macro AUROC 最高的那个（结果是 CNN-BiLSTM 从头训练，仅领先 ResNet1d 0.0001）。全程没有用测试集挑方案。

5.3 统计方法

- 3 个种子的预测概率先取平均（种子集成），再算结论矩阵和配对检验。
- 置信区间：测试集按记录重抽样 1,000 次（bootstrap）。配对比较时两个模型用同一批重抽样。
- 29 个架构 / 导联 / 策略比较一起做 **Holm 多重比较校正**；只有校正后 $p < 0.05$ 才叫“显著”。1,000 次 bootstrap 的分辨率是 $p < 0.001$，所以不会写“$p = 0$”。

5.4 防泄漏与可复现

标准化参数、阈值、温度缩放、早停、主方案选择全部只用训练 / 验证集；测试集和外部数据只在最后评估一次。每次改代码前后都在假数据上跑同一个 CPU 回归测试，结果必须一模一样才算通过。

6 实验清单

编号	回答什么问题	训练次数
E0	基线 B0–B2（12lead、leadI；T1、T2）	只用 CPU
E1	12 导联下三种架构比较	3 模型 × 3 种子 = 9
E1b	消融：去掉残差、卷积核 3/15/31、普通 RNN 代替 LSTM、类别加权损失	6（种子 0）
E2	减导联，从头训练	3 模型 × 5 配置 × 3 种子 = 45
E3	训练策略：S2 微调 15 + S2 冻结 3 + S3 LA-ResNet 3	21
E4	T2 正常 / 异常分诊	9
E5	标签效率：只用 10% / 25% / 50% 的训练病人	12（种子 0）
E6	测试时加噪声（20 / 10 / 5 / 0 dB）、亚组、集成、分歧分析、可解释性	不需重新训练
E7	外部医院验证（模型冻结，不重训）	0
E8	自监督预训练 + 10% 标签微调	2 预训练 + 12 微调

7 主要结果

7.1 RQ1：12 导联下三种架构差不多，都远好于传统方法

模型	macro AUROC（3 种子）	AUPRC	sens@spec90	ECE	种子集成 AUROC [95% CI]
B0 先验	0.500	0.259	0.000	—	—
B1 原始波形 LR	0.512	0.287	0.142	0.111	—
B2 特征 LR	0.863	0.701	0.627	0.028	—
ResNet1d	0.9227 ± 0.0015	0.816	0.777	0.033	0.9298 [0.923, 0.937]
CNN-BiLSTM	**0.9253 ± 0.0013**	0.817	0.773	0.039	0.9292 [0.923, 0.936]
ECG-ViT	0.9147 ± 0.0009	0.795	0.752	0.043	0.9221 [0.915, 0.930]

- 三个深度模型都在 0.915–0.925 之间，和公开的 PTB-XL 排行榜（0.921–0.930）重叠，说明我们自己写的实现是靠谱的。
- ResNet1d 和 CNN-BiLSTM 集成后的差值只有 +0.0005（95% CI -0.0020 到 $+0.0031$，Holm 校正后 $p = 1.000$），**不能说谁更好**。
- ECG-ViT 稍弱，符合“数据量不大时 Transformer 缺少局部先验”的常见经验。
- 消融（只跑了种子 0）：去残差、改卷积核、换普通 RNN 的差别都很小，单种子的小差别不能下结论。

7.2 RQ2：导联越少越差，Lead I 掉得最多

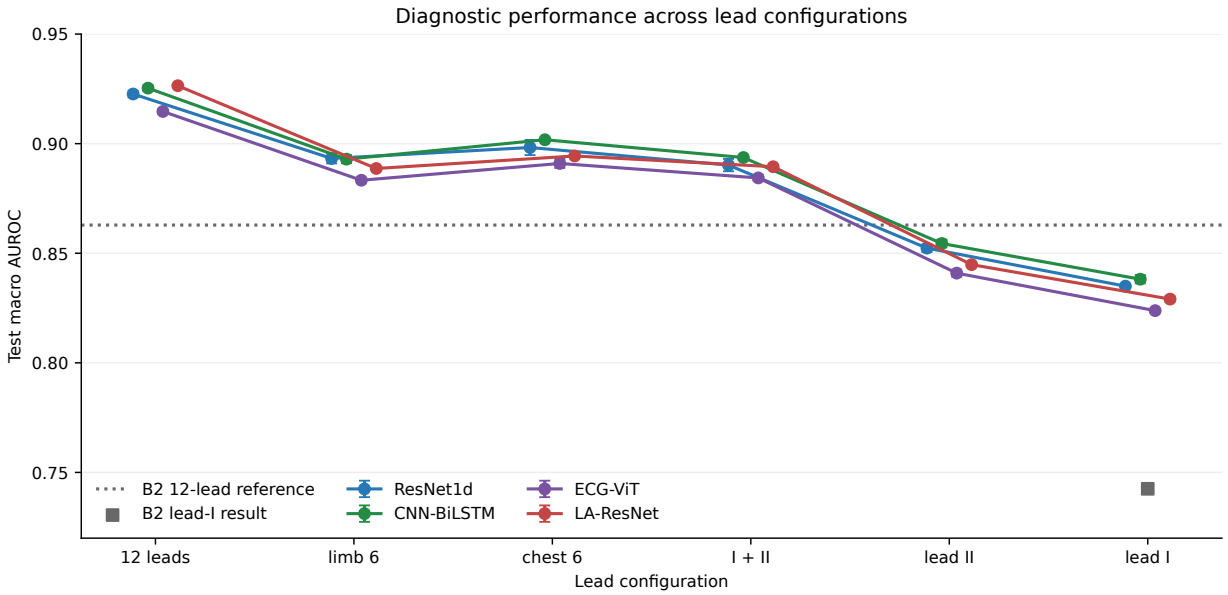


图 2: 六种导联配置下的测试集 macro AUROC（3 个种子的均值）。虚线是 B2 在 12 导联上的结果，灰色方块是 B2 在 Lead I 上的结果（0.743）。

种子集成 AUROC	12lead	limb6	chest6	2lead	leadII	leadI
ResNet1d	0.930	0.899	0.905	0.897	0.859	0.840
CNN-BiLSTM	0.929	0.897	0.905	0.897	0.857	0.841
ECG-ViT	0.922	0.890	0.897	0.890	0.846	0.829
LA-ResNet（一个模型）	0.931	0.894	0.900	0.893	0.849	0.832

- ResNet1d 从 12 导联到 Lead I，AUROC 掉了 **0.090**（95% CI 0.081–0.100）。
- 胸前 6 导联（chest6）是减少配置里最好的；只剩一个导联（II 或 I）时下降明显加大。
- 但**平均值掩盖了差别**：不同诊断掉得很不一样，见下面的结论矩阵。

7.3 结论矩阵：30 个格子只有 1 个过关

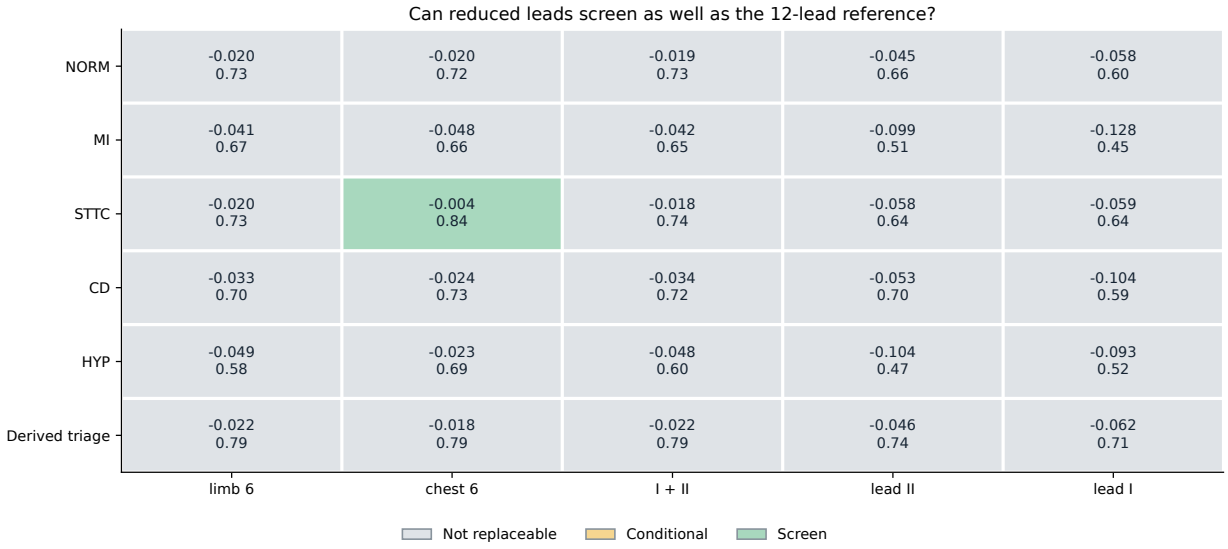


图 3: 主方案（CNN-BiLSTM，验证集选出）的结论矩阵。每格上面是 ΔAUROC（减导联 − 12 导联），下面是特异度 90% 时的灵敏度。绿色 = 可初筛，灰色 = 不能替代。

怎么读这张图

- 5 个诊断 × 5 种减少配置 = 30 个格子，**29 个“不能替代”**，只有 **STTC + chest6 “可初筛”**：ΔAUROC = −0.004（95% CI −0.010 到 +0.001），灵敏度 0.84。
- 这个格子在我们评估的**全部 5 种方案**里都过关（Δ 在 −0.009 到 −0.005，灵敏度 0.82–0.84），所以不是挑方案挑出来的。直觉上也说得通：ST/T 改变在胸前导联上本来就最明显。
- **Lead I 一个都没过**。最差的是 MI（心梗）：AUROC 从 0.924 掉到 0.796（Δ = −0.128, 95% CI −0.147 到 −0.107），灵敏度只有 **0.45**——也就是说同样的误报率下，一半以上的心梗会被漏掉。
- 把阈值 0.02 换成 0.01，结论不变；换成更宽松的 0.03，会多出 8 个“有条件”，但仍然只有 1 个“可初筛”。

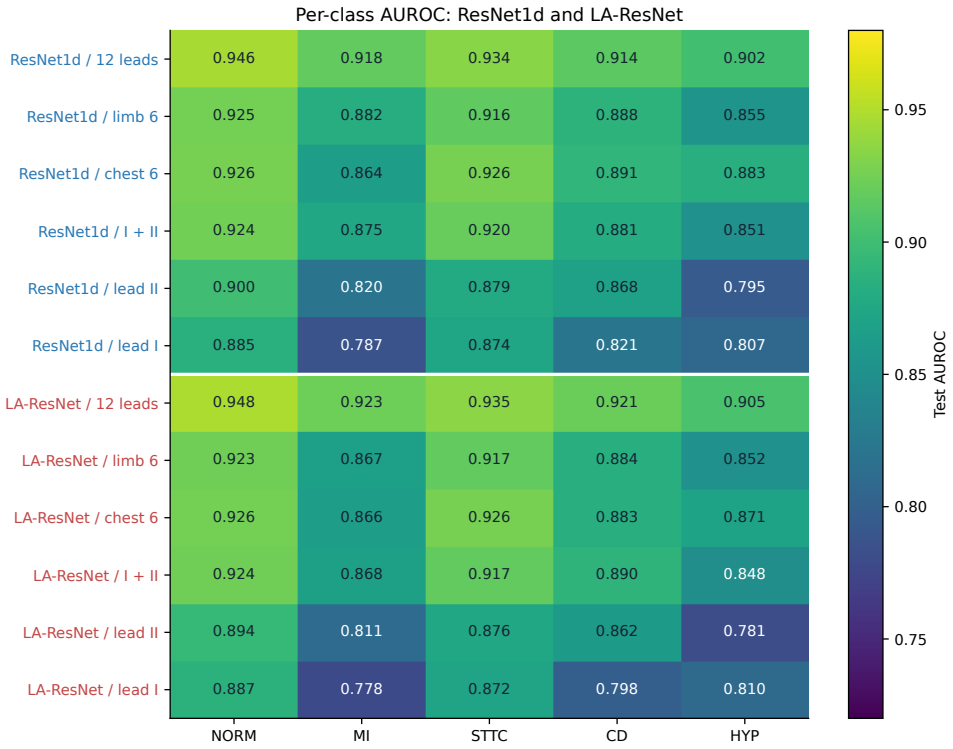


图 4: ResNet1d 和 LA-ResNet 每个诊断大类在各导联配置下的测试 AUROC。MI 在单导联上掉得最多（ResNet1d 0.918 → 0.787），HYP 在 Lead II 上最低；STTC 在胸前 6 导联上几乎不掉（0.934 → 0.926）。

7.4 RQ2：训练策略补不回来丢掉的信息

- **S2 迁移学习（微调）**：和从头训练相比，5 种减少配置上 AUROC 变化只有 -0.0023 到 $+0.0022$，Holm 校正后全部不显著（$p = 0.73$–1.00）。冻结主干在 Lead I 上反而差 0.0078（显著）。
- **S3 LA-ResNet**：比 5 个单独训练的模型低 0.003–0.010（chest6、leadII、leadI 显著），但换来的是**一个模型通吃 6 种配置**；在 12 导联上 0.9264 ± 0.0004，并不比 ResNet1d 差。这是一个“少量性能换部署方便”的权衡。
- **标签效率（E5）**：12 导联上训练数据从 100% 减到 10%，AUROC 掉 0.040（0.921 → 0.881）；但 Lead I 上从 10% 加到 100% 只涨了 0.023（0.812 → 0.835）。**甚至 10% 数据的 12 导联模型（0.881）都比 100% 数据的 Lead I 模型（0.835）好**。说明 Lead I 的瓶颈主要是**输入里的信息不够**，而不是数据不够。

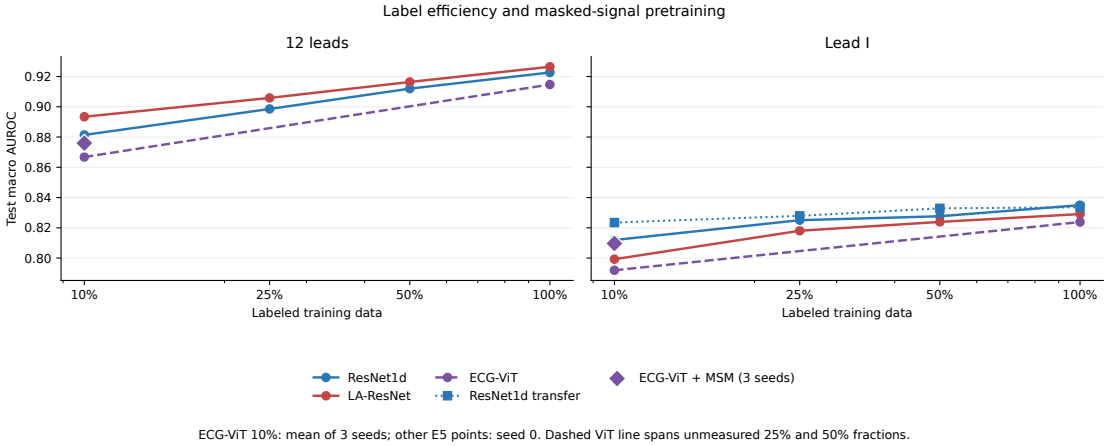


图 5: 标签效率：训练数据比例与测试 AUROC。12 导联的曲线陡，Lead I 的曲线平。

7.5 RQ3：自监督预训练帮了 Transformer（E8）

只用 10% 标签的 ECG-ViT	从头训练（3 种子均值 ± SD）	先自监督再微调	差值 [95% CI]
12lead	0.8668 ± 0.0078	0.8759 ± 0.0006	+0.0065 [+0.0020, +0.0112]
leadI	0.7919 ± 0.0026	0.8096 ± 0.0005	+0.0149 [+0.0091, +0.0210]

两个提升在 Holm 校正后都显著，而且种子间的波动大幅变小（12 导联 SD 0.0078 → 0.0006）。但要注意：预训练跑满了 100 个 epoch 还没完全收敛；提升后的水平也只是和同样 10% 标签的 ResNet1d 差不多（0.881 / 0.812），不能说它是最好的方法。

7.6 RQ3：噪声、分诊和外部医院

噪声鲁棒性。 测试时往信号里加白噪声。干净的 Lead I 上 CNN-BiLSTM 略好（0.838 vs 0.835），但在最强的 0 dB 噪声下，ResNet1d 0.759 明显好于 CNN-BiLSTM 0.686——**干净数据上的排名在噪声下会反过来**。

T2 正常 / 异常分诊。 内部测试集上 12 导联 AUROC 0.940，Lead I 0.878；但 Lead I 在特异度 90% 时灵敏度只有 0.71，没达到 0.80 的初筛门槛。专门训练 T2 和从 T1 推出分诊分数，Lead I 灵敏度都在 0.70–0.71 左右。

外部医院（E7）。 冻结模型直接拿去 Chapman 34,815 条数据上测：12 导联 0.955，Lead I 0.916，甚至比内部还高。但这**不代表泛化更好**：外部的“正常”定义更严格（必须全是窦性心律），病例构成也不同；如果把“左室高电压”也算成异常（v2_lvhv 敏感性分析），数值就回落到 0.936 / 0.880，和内部差不多。另外，直接搬用 PTB-XL 上定的阈值，外部特异度变成 86%–90%，说明**真要部署必须在当地重新校准阈值**。

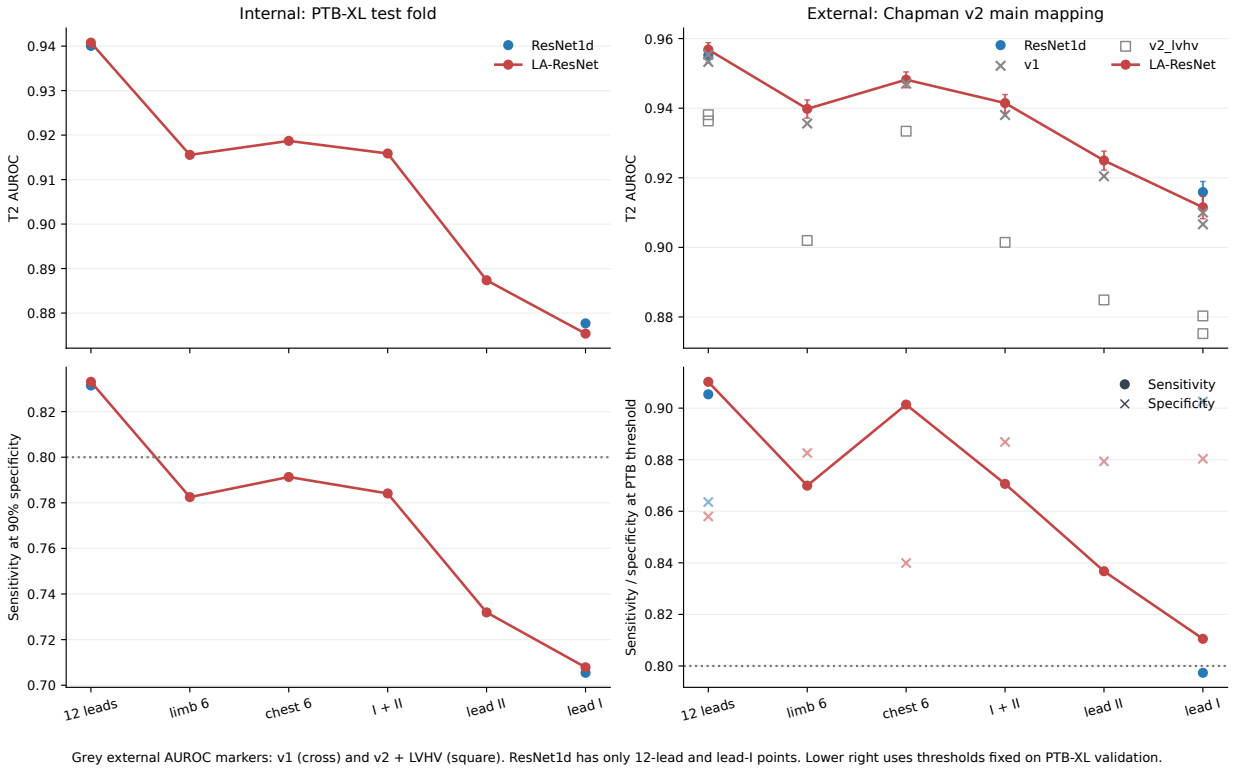


图 6: 左：PTB-XL 内部的分诊表现；右：Chapman 外部数据在三种标签映射下的 AUROC，以及搬用 PTB-XL 阈值后的灵敏度 / 特异度。

其他分析。 多个模型意见最不一致的 20% 记录，错误率是其余记录的 2.3 倍（12 导联）和 1.8 倍（Lead I），可以考虑用来标记“需要人工复核”的记录（但没有测试真实的转诊策略）。Grad-CAM 和注意力图只作为示意：ResNet1d 的感受野比整段输入还长，所以热图只能指出大致区域；ViT 注意力里有一条很亮的竖线，更像“注意力汇聚点”（attention sink）而不是生理机制。

8 结论：带走这四句话

1. **用规则判，而不是看平均值**：按事先定好的初筛规则逐格判定，30 格里 29 格不能替代 12 导联，只有“胸前 6 导联筛 ST/T 改变”过关。
2. **一个模型可以服务六种导联**：LA-ResNet 用导联掩码，只损失 0.003–0.010 AUROC，就换来一个统一的部署模型。
3. **瓶颈是信息，不是方法**：迁移学习和 10 倍的标签对 Lead I 都几乎没用；自监督预训练能帮 Transformer，但补不上信息差。
4. **单导联适合做分诊辅助，不适合做诊断**：Lead I 分诊 AUROC 0.88，但灵敏度 0.71 不够独立初筛；换医院后阈值也会漂移。

局限性（答辩时可能被问）

- 我们的 Lead I 来自**医院 12 导联里截出来的 Lead I**，不是真正的手表录的（手表有运动伪影、电极接触差等问题）。
- 只在一个训练集（PTB-XL）、100 Hz 下训练；噪声是人工加的白噪声，不是真实噪声。
- 标签效率和消融只跑了 1 个种子，小差别没有跨种子的不确定性估计。
- 亚组（性别、年龄）结果只是描述，没有置信区间，不能下公平性结论。
- 下一步：用同时录了手表和 12 导联的配对数据来验证。

9 常见问题（答辩准备）

初筛规则是不是随便定的?
是在看结果之前定好的；把 0.02 换成 0.01 或 0.03，“可初筛”的格子数都还是 1 个。

为什么主方案是 CNN-BiLSTM?
按验证集选的（只领先 0.0001）；而且唯一过关的 STTC-chest6 在全部 5 种方案里都过关，选哪个都不影响结论。

有没有数据泄漏?
官方按病人分折；标准化、阈值、温度缩放都只用训练 / 验证集；测试集只评估一次。

外部 AUROC 为什么比内部还高?
外部标签更严格、病例构成不同；把左室高电压算进去后就回落到内部水平。

B1 为什么几乎是瞎猜?
原始时间点在不同记录之间没对齐；改用平移不变特征的 B2 就到了 0.863。

为什么用 100 Hz?
PTB-XL 基准的标准设置，也让 100 多次训练能在一块 GPU 上跑完。

代码是不是自己写的?
是。所有模型（包括手写的多头自注意力）、训练循环、指标和统计检验都在 `src/` 和 `scripts/` 里，从头写在 PyTorch 上。

10 术语小词典

术语	解释
AUROC	ROC 曲线下面积，模型把病人排在健康人前面的概率；0.5 瞎猜，1 完美
sens@spec90	特异度固定在 90%（健康人 10% 误报）时的灵敏度（病人被抓出的比例）
ECE / 温度缩放	校准误差：模型说“80% 有病”时是否真有 80% 有病；温度缩放是在验证集上调一个系数让概率更准
Bootstrap	对测试集有放回地重抽样很多次，看指标的波动，用来算置信区间
配对检验	两个模型在同一批重抽样上比较，消掉“样本运气”的影响
Holm 校正	做很多次检验时防止“碰巧显著”的多重比较校正方法
种子集成	同一配置的 3 个随机种子模型把概率取平均
macro	对 5 个类别分别算指标再取平均
感受野	卷积网络最后一层的一个位置能“看到”输入的多长范围
Grad-CAM	用梯度画热图，显示模型主要看了信号哪一段
MSM	Masked Signal Modelling，遮住一部分信号让模型补全的自监督预训练

11 压缩包里有什么、怎么用

11.1 目录导览

路径	内容
`00_ 项目简介.pdf`	就是本文
`README.md`	代码说明、运行步骤（中文）
`PROJECT_PLAN.md`	项目总账：计划、进度、每一轮审查记录（R-xxx）和变更（CR-x）
`BS6204 项目大纲 / 说明书.pdf`	最早的项目设计和原理讲解
`src/`	核心代码：数据（`data.py`）、模型（`models.py`）、训练（`train.py`）、指标与统计（`metrics.py`）、Grad-CAM
`scripts/`	各实验和汇总脚本：基线、实验网格、汇总出图、结论矩阵、集成与亚组、E7 外部验证、E8 自监督、论文图
`*.bat`	Windows 下按编号双击运行的启动脚本（0–8）
`docs/`	任务定义、报告 / PPT 大纲、`06_key_findings.md`（12 条关键发现及数据来源）
`docs/report/`	英文报告 PDF（v0.3）和 LaTeX 源文件
`results/summary/`	所有汇总表格和图：`all_runs.csv`、配对检验、结论表、fig1–fig11
`results/summary/paper_figs/`	报告用的论文级图 A–H（PDF + PNG）和表 1–5
`results/summary/external_*`	E7 外部验证三种映射的结果
`results/eda/`	数据描述图表
`results/<run>/`	每次训练的配置（config.json）、训练曲线（history.csv）、测试指标（metrics.json）

11.2 没放进去的东西

原始数据(PTB-XL 约 3 GB、Chapman 数据)、模型权重(`*.pt`)、每次训练的预测文件(`preds.npz`)、TensorBoard 日志、运行日志、假数据测试结果（`results_mock`）都不在包里，PPT 也不在包里（单独提交)。所以:

- **只看结果**：直接打开 `results/summary/` 和 `docs/report/` 就够了；
- **要完整复现**：按 `README.md` 第 3 节，下载 PTB-XL v1.0.3 放到 `data/ptb-xl`，然后依次运行：`0_check_env.bat` → `2_prepare_ptbxl.bat` → 编号 3–6 的训练脚本 → `7_analyse.bat`；E7、E8 的命令在 README 里。需要 NVIDIA GPU，全部训练要跑很多个小时。
- 想先确认代码能跑：`1_smoke_test_mock.bat` 会用假数据把整个流程跑一遍（10–20 分钟），结果没有意义，只是检查代码。

11.3 推荐阅读顺序

1. 本文（15 分钟)；
2. `docs/06_key_findings.md`：12 条关键发现，每条都写了数字和对应文件；
3. `docs/report/Twelve_to_One_report_draft_v0.3.pdf`：正式英文报告；
4. 想看代码从 `src/models.py` 和 `src/train.py` 开始。

本文所有数字都来自 `results/summary/` 下的文件和报告 v0.3；如果和英文报告有出入，以报告为准。